

Instituto Politécnico Nacional

Centro de Investigación en Computación (CIC)

Departamento de diplomados y extensión profesional

Diplomado en Python y Ciencia de Datos

Práctica 1

Introducción a las redes neuronales de una capa

Profesor Alan Badillo Salas

Semana 1. Agosto 2026.

1. Introducción

En la ciencia de datos, un problema bien planteado se logra al observar un fenómeno a través de datos. Las muestras recopiladas de las observaciones componen registros con diferentes tipos de datos, generalmente numéricos y categóricos. Cada observación se compone de diferentes características, formando así el espacio de características. Sin embargo, los modelos matemáticos están diseñados para operar en espacios numéricos, por lo que el espacio de características es transformado a un espacio numéricos, haciendo que las características que son categóricas se representen de forma numérica a través de dos técnicas:

1. **Expansión de la característica** - Cada característica categórica se expande en características binarias, una por categoría, y estas responden con 1 si la observación para esa característica está en la categoría indicada. Es decir, si se tiene una característica categórica $C_j \in \{A, B, C, \dots\}$ con categorías $A, B, C, \dots$, entonces se crearán las características numéricas $C_j^{(A)}, C_j^{(B)}, C_j^{(C)}, \dots \in \{0, 1\}$, donde $C_j^{(A)}$ tomará el valor de 1 si $C_j = A$, o 0 en otro caso, y de forma similar para las categorías restantes. A estas características expandidas se les conoce como *dummies*. Además para no sobreinformat al sistema con todas las combinaciones lineales, quitaremos la categoría de mayor frecuencia y le llamaremos la *categoría base*, la cual representará la categoría común cuando ninguna otra se activa. A este proceso se le conoce como codificación **one-hot**.
2. **Transformación directa** - Cuando podemos asignar un valor numérico directamente a cada categoría, por ejemplo, porque hay un orden o una ponderación asociada, entonces podemos evitar expandir la característica en muchas características y simplemente transformar cada categoría en su valor directo. Existen diferentes transformaciones, como sustituir la categoría por un número natural consecutivo, usar el promedio, mediana, desviación estándar o algún estadístico derivado de los elementos en esa categoría, o incluso contruir indicadores más complejos como el número de veces que incrementa el promedio de una categoría respecto a la categoría base o la fijada como común.

Una vez que todos los datos son numéricos, podemos establecer un espacio de análisis donde separamos las características predictivas X y las respuestas que deseamos entender Y a través de las predictivas. A este lo podemos analizar partiendo del predictor lineal $X \cdot \beta$, donde $\beta = (\beta_0, \beta_1, \dots, \beta_k)$ es un vector de parámetros para cada característica predictiva $x_1, \dots, x_k$ y considera un *bias* como parámetro β_0 para considerar efectos no influenciados por las predictivas. El modelo lineal forma un eje $z = X \cdot \beta$ y un modelo lineal $\phi(X, \beta) = X \cdot \beta$ o simplemente $\phi(z) = z$, donde $\hat{y} = \phi$, por lo que podemos analizar los ejes $(z, \phi(z))$ o en términos de predicción $(z, \hat{y})$ y ajustar el modelo con los datos conocidos de $(x^{(i)}, y^{(i)})$, de cada i -ésima observación.

Entonces, el modelo lineal formulado, permite aproximar los datos de la respuesta a través de un espacio lineal continuo, y por lo tanto se deriva en un proceso de optimización, para encontrar las mejores β^* partiendo de una β cualquiera. Para lograr esto se debe medir el error entre la observación y la predicción del modelos, definido como $\varepsilon = y - \hat{y}$. Sin embargo, el error no plantea una forma de optimización, por lo que se define un espacio que deforma el error mediante una función de pérdida del error, de tal manera que este tenga un mínimo, para de esta forma optimizar la pérdida del error, y así llegar a un error mínimo entre el modelo de predicción y los datos.

Dependiendo el tipo de modelo, algunas funciones de pérdida serán mejores que otras, o más sencillas de definir y derivar, como $L(\varepsilon) = \frac{1}{2} \varepsilon^\top \cdot \varepsilon$ que representa una buena pérdida ya que $\nabla_\beta L = \varepsilon \cdot \nabla_\beta \varepsilon$.

Finalmente, con estas ideas podemos construir un mecanismo de optimización de las $\beta^{(t)}$ para descubrir la $\beta^{(t+1)}$ que sea más cercana al mínimo de $L(\varepsilon)$. Así, $\beta^{(t+1)} = \beta^{(t)} + \eta \nabla_\beta L$, optimizará las β desde la inicial $\beta^{(0)}$ mediante el descenso por gradiente. Aunque también existen métodos más potentes y avanzados como *Newthon-Raphson*, *BFGS*, *SGD*, *ADAM*, entre otros.

En esta **Práctica 1**, implementaremos un análisis completo del espacio de características, el espacio numérico, el espacio de análisis, el espacio lineal y construiremos un perceptrón lineal simple como resultado natural de todo este análisis, usando el optimizador de descenso por gradiente.

Analiza el código desarrollado en la práctica, resuelve los dos problemas teóricos y responde las preguntas de la práctica. En un documento **PDF** con una portada que contenga la identidad del *Instituto Politécnico Nacional*, el *Centro de Investigación en Computación* y el *Departamento de diplomados y extensión profesional*, con tu nombre completo, correo, así como lugar y fecha, documenta los resultados de la práctica y envíalos por correo a **badillosalas@outlook.com** con el título **Diplomado PyCD 2026 - Práctica 1**. No es necesario poner cuerpo en el correo o adjuntar más archivos, solo el documento PDF es suficiente. El documento PDF se debe llamar *pycd26_SIGLAS.pdf* con las **SIGLAS** formadas por tu nombre y apellidos.

1.1. Problema 1 - Comparación del error entre dos β que son distintas en el modelo lineal

Dadas los siguientes puntos observados de x y y , determina el vector de error y la pérdida para la $\beta^{(0)} = (1, 2)$ y para $\beta^{(0)} = (1, 3)$ en el modelo lineal.

x	y
1	3
2	5
3	8

1.1.1. Procedimiento

Primero construye el espacio lineal $z = \beta_0^{(0)} + \beta_1^{(0)} \cdot x$, es decir, $z = 1 + 2x$ para $\beta^{(0)} = (1, 2)$ y $z = 1 + 3x$ para $\beta^{(0)} = (1, 3)$ y genera las tablas asociadas.

x	y	z
1	3	.
2	5	.
3	8	.

Luego predice la respuesta para cada y , sabiendo que el modelo lineal hace que la predicción $\hat{y} = \hat{x} \cdot \beta^{(0)} = z$, por lo que simplemente hay que copiar la misma columna de z como predicción $\hat{y}$ ($\hat{y} = z$).

x	y	z	$\hat{y} = z$
1	3	.	.
2	5	.	.
3	8	.	.

Calcula el error en cada predicción y , mediante $\varepsilon = y - \hat{y}$ y aumenta la columna del error ε .

x	y	z	$\hat{y} = z$	ε
1	3	.	.	.
2	5	.	.	.
3	8	.	.	.

Ahora determina la pérdida del error cuadrático $L = \frac{1}{2}\varepsilon^2$, extiende la columna de la pérdida L para cada observación.

$\mathbf{x}$	$\mathbf{y}$	$\mathbf{z}$	$\hat{y} = z$	ε	$L = \frac{1}{2}\varepsilon^2$
1	3	.	.	.	.
2	5	.	.	.	.
3	8	.	.	.	.

Ahora, suma la columna L para obtener la pérdida total para la $\beta^{(0)}$ y reporta su valor.

1.1.2. Preguntas de análisis del Problema 1

Responde las siguientes preguntas:

1. ¿Qué representa z ?
2. ¿Es diferente graficar x contra y que z contra y ? ¿Por qué?
3. ¿Qué $\beta^{(0)}$ tiene menor pérdida total, $\beta^{(0)} = (1, 2)$ o $\beta^{(0)} = (1, 3)$? ¿Cuáles son los valores de las pérdidas en cada uno?
4. Si graficamos la recta que forma z contra $\hat{y}$ y ponemos los puntos de y en la respectiva z , ¿Se observa algún ajuste lineal? ¿Cómo lo explicas? Prueba con ambas $\beta^{(0)} = (1, 2)$ o $\beta^{(0)} = (1, 3)$
5. ¿Qué representa la gráfica de z contra L ? ¿Parece una parábola?

1.2. Problema 2 - Comparación del error entre dos β que son distintas en el modelo logístico

En el **Problema 1** ajustamos el modelo lineal a los datos conocidos de x y y con dos $\beta^{(0)}$ distintas, pero, ahora vamos a pensar que la respuesta y no es abierta, sino cerrada, y queremos ajustar un modelo logístico (no lineal) conocido como el modelo de activación. Este modelo consiste en ajustar $\phi(z) = \sigma(z) = \frac{\exp(z)}{1+\exp(z)}$ que se conoce como la función logística $\sigma(z)$. El procedimiento es el mismo, solo que la predicción $\hat{y}$ ya no es $\hat{y} = z$, sino $\hat{y} = \sigma(z)$. Además, ahora usaremos una nueva función de pérdida más adecuada para el modelo logístico, que será $L = -y \ln(y - \varepsilon) - (1 - y) \ln(1 - y + \varepsilon)$ que se conoce como la función de pérdida de la entropía cruzada binaria.

Dadas los siguientes puntos observados de x y y , determina el vector de error y la pérdida para la $\beta^{(0)} = (1, 2)$ y para $\beta^{(0)} = (1, 3)$ en el modelo lineal.

x	y
1	0
2	0
3	1
4	1

1.2.1. Procedimiento

Primero construye el espacio lineal $z = \beta_0^{(0)} + \beta_1^{(0)} \cdot x$, es decir, $z = 1 + 2x$ para $\beta^{(0)} = (1, 2)$ y $z = 1 + 3x$ para $\beta^{(0)} = (1, 3)$ y genera las tablas asociadas.

x	y	z
1	0	.
2	0	.
3	1	.
4	1	.

Luego predice la respuesta para cada y , sabiendo que el modelo lineal hace que la predicción $\hat{y} = \dot{x} \cdot \beta^{(0)} = z$, por lo que simplemente hay que copiar la misma columna de z como predicción $\hat{y}$ ($\hat{y} = \sigma(z)$).

x	y	z	$\hat{y} = \sigma(z)$
1	0	.	.
2	0	.	.
3	1	.	.
4	1	.	.

Calcula el error en cada predicción y , mediante $\varepsilon = y - \hat{y}$ y aumenta la columna

del error ε .

$\mathbf{x}$	$\mathbf{y}$	$\mathbf{z}$	$\hat{y} = \sigma(z)$	ε
1	0	.	.	.
2	0	.	.	.
3	1	.	.	.
4	1	.	.	.

Ahora determina la pérdida del error mediante la entropía cruzada binaria con $L = -y \ln(y - \varepsilon) - (1 - y) \ln(1 - y + \varepsilon)$, extiende la columna de la pérdida L para cada observación.

$\mathbf{x}$	$\mathbf{y}$	$\mathbf{z}$	$\hat{y} = \sigma(z)$	ε	L
1	0	.	.	.	.
2	0	.	.	.	.
3	1	.	.	.	.
4	1	.	.	.	.

Ahora, suma la columna L para obtener la pérdida total para la $\beta^{(0)}$ y reporta su valor.

1.2.2. Preguntas de análisis del Problema 2

Responde las siguientes preguntas:

1. ¿Sigue z representando lo mismo? ¿Por qué?
2. ¿Es diferente graficar x contra y que z contra y ? ¿Por qué?
3. ¿Qué $\beta^{(0)}$ tiene menor pérdida total, $\beta^{(0)} = (1, 2)$ o $\beta^{(0)} = (1, 3)$? ¿Cuáles son los valores de las pérdidas en cada uno?
4. Si graficamos la curva que forma z contra $\hat{y}$ y ponemos los puntos de y en la respectiva z , ¿Cómo se comporta la gráfica? ¿Cómo lo explicas? Prueba con ambas $\beta^{(0)} = (1, 2)$ o $\beta^{(0)} = (1, 3)$
5. ¿Qué representa la gráfica de z contra L ? ¿Parece una parábola?

1.3. Preguntas de análisis de la práctica

Sobre el código de la práctica, responde las siguientes preguntas de análisis:

1. ¿Se puede estudiar un fenómeno sin datos mediante la ciencia de datos?
2. ¿Qué tipos de datos existen y cómo se representan en un conjunto de datos?
3. ¿Qué es el espacio de características?
4. ¿Por qué se requiere transformar todas las características a valores numéricos?
5. ¿Cómo se analiza una característica que es categórica?
6. ¿Cómo se analiza una característica que es numérica?
7. ¿Cómo se visualiza una característica categórica?
8. ¿Cómo se visualiza una característica numérica?
9. ¿Cómo se visualiza la influencia entre una característica categórica y otra característica categórica?
10. ¿Cómo se visualiza la influencia entre una característica categórica y una característica numérica?
11. ¿Cómo se visualiza la influencia entre una característica numérica y una característica categórica?
12. ¿Cómo se visualiza la influencia entre una característica numérica y otra característica numérica?
13. ¿Cómo se visualiza la influencia entre una característica numérica y otra característica numérica?
14. ¿Cómo se transforma una característica categórica en varias características numéricas? ¿Cómo se llaman las características expandidas? ¿Cómo se le llama a esta codificación? ¿Qué se debe considerar con la característica de mayor proporción?
15. ¿Cómo se transforma una característica categórica en otra característica numérica por lógica directa? ¿Qué se debe considerar sobre las categorías? ¿Tienen sentido estas transformaciones?
16. Si una característica categórica se transforma en el promedio de otra característica numérica solo para los registros que cumplen esa categoría, entonces, ¿Se podría usar la respuesta numérica para esta transformación o se crearía un problema de fuga de información (*leakage*)? Investiga al respecto para responder

17. Si tenemos más de una característica en el modelo lineal, ya no podemos visualizar de forma simple la influencia de las $x_1, x_2, \dots, x_k$ en la respuesta y , pero si de $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$, por eso es importante el espacio lineal, entonces, ¿Qué representa la gráfica de z contra y ?
18. ¿Para graficar z contra y requerimos conocer los valores de $x_1, x_2, \dots, x_k$ o solo los valores que tomará z ?
19. ¿Por qué al actualizar se usa $\beta^{(t+1)} = \beta^{(t)} + \eta \varepsilon x$?
20. ¿Qué representa la gráfica de z contra L ?

2. Método de evaluación

Cada pregunta respondida correctamente tendrá valdrá 1 punto, y cada respuesta aproximada solo medio punto. Hay 30 puntos totales en esta práctica. No hay fecha de entrega programada, tienen el resto del módulo para resolver la práctica, serán 3 prácticas totales y dos de ellas deberán aprobarlas con una calificación mayor a 6/10.

Mucho éxito en su práctica :D