

Instituto Politécnico Nacional

Centro de Investigación en Computación (CIC)

Departamento de diplomados y extensión profesional

Diplomado en Python y Ciencia de Datos

Práctica 2

Introducción a las redes neuronales multicapa

Profesor Alan Badillo Salas

Semana 2. Septiembre 2026.

Introducción

En la ciencia de datos, el aprendizaje profundo ha tomado relevancia gracias a las redes neuronales multicapa, las cuales son capaces de generar modelos no lineales complejos que son capaces de predecir respuestas, generando así un mecanismo de aprendizaje supervisado útil y de buen rendimiento, una red neuronal multicapa consta principalmente de tres tipos capas:

1. **Capa de entrada** - Esta no contiene neuronas, sino que codifica el vector de entrada $x^{(i)}$ para cada observación.
2. **Capas ocultas** - Estas definen un conjunto de neuronas con una misma función de activación, la cual se alimenta del vector de la capa anterior, por ejemplo, $x^{(i)}, h^{(1)}, h^{(2)}, \dots$, produciendo un vector de respuesta intermedia $h^{(l)}$.
3. **Capa de salida** - Esta capa considera una neurona para cada respuesta requerida, y donde la activación de esa respuesta debe permitir construir el mismo espacio que la respuesta, por ejemplo, en respuestas abiertas se puede tener una activación lineal y en respuestas cerradas una activación logística. Cada neurona en la capa de salida se considera el predictor de respuesta $\hat{y}_j$ para la j -ésima salida.

Al igual que un único perceptrón, la red neuronal requiere de una función de pérdida asociada y un optimizador, esto formará capas densas que serán optimizadas de forma similar al perceptrón, pero retropropagando el gradiente (jacobiano) del error para cada capa oculta $h^{(l)}$. A este método se le conoce como la **retropropagación (backpropagation)**.

El modelo matemático para definir la siguiente capa oculta de activación uniforme y matriz de pesos $B^{(l+1)}$ es:

$$h^{(l+1)} = \Phi_{l+1}(h^{(l)}, B^{(l+1)})$$

donde $\Phi_{l+1}(h^{(l)}, B^{(l+1)})$ es el vector de la respuesta intermedia $h^{(l+1)}$ que será el vector de entrada para la siguiente capa. Así podemos pensar $h^{(0)} = x^{(i)}$ como la capa oculta almohadilla, $h^{(1)} = \Phi_1(h^{(0)}, B^{(1)})$ la primera capa oculta con una matriz de pesos $B^{(1)} = (B_1^{(1)}, B_2^{(1)}, \dots, B_{l_1}^{(1)})$, donde cada $B_\nu^{(1)}$ es el vector de pesos asociado a la neurona ν , por eso, cada capa oculta tiene una matriz de pesos, equivalente a una colección de vectores de pesos, uno para cada neurona (donde la neurona se entiende como un perceptrón individual). Luego se continúa así con $h^{(2)} = \Phi_2(h^{(1)}, B^{(1)})$, haciendo que la segunda capa oculta tome como entrada la primera capa oculta y su función de activación Φ_2 . Este proceso permite encadenar todas las capas que se alimentan desde $h^{(0)} = x^{(i)}$ y llegan a $h^{(s)}$ que es esencialmente la última capa de salida.

Para lograr la optimización se requieren dos piezas fundamentales de derivación, la primera es el gradiente de $\Phi_{l+1}(h^{(l)}, B^{(l+1)})$ respecto a las $h^{(l)}$, el cual es

un vector de gradientes conocido como el Jacobiano $J_{h^{(l)}}$. Luego el gradiente de $\Phi_{l+1}(h^{(l)}, B^{(l+1)})$ respecto a los pesos $B^{(l+1)}$ que también es un Jacobiano $J_{B^{(l+1)}}$. Teniendo, entonces:

$$J_{h^{(l)}} = \frac{\partial h^{(l+1)}}{\partial h^{(l)}} = \frac{\partial \Phi_{l+1}}{\partial h^{(l)}}$$

Y también

$$J_{B^{(l+1)}} = \frac{\partial h^{(l+1)}}{\partial B^{(l+1)}} = \frac{\partial \Phi_{l+1}}{\partial B^{(l+1)}}$$

Y así, el punto crítico será cómo retropropagar el error, el cuál se divide en dos piezas, la primera es $\varepsilon^{(s)}$ que es el error en la capa de salida, medido a través de la función de pérdida $L(\varepsilon^{(s)})$ y $\varepsilon^{(l)}$ que es el error que se retropropaga a la capa anterior, teniendo así:

$$\varepsilon^{(s)} = -\frac{\partial L}{\partial h^{(s)}}$$

Y también,

$$\varepsilon^{(l)} = J_{h^{(l)}}^\top \varepsilon^{(l+1)}$$

donde la última capa oculta conecta $h^{(l+1)=h^{(s)}}$ que es la capa de salida.

Para el caso del error cuadrático medio $L = \frac{1}{2} \|\varepsilon\|^2 = \frac{1}{2} \|y - h^{(s)}\|^2$, tendríamos:

$$\varepsilon^{(s)} = -\frac{\partial L}{\partial h^{(s)}} = -\varepsilon \frac{\partial \varepsilon}{\partial h^{(s)}} = \varepsilon(-1) = \varepsilon = y - h^{(s)}$$

Finalmente, para que la retropropagación esté completa tenemos la actualización de pesos por descenso del gradiente como:

$$B^{(l+1)*} = B^{(l+1)} + \eta J_{B^{(l+1)}}^\top \varepsilon^{(l+1)}$$

Completando así el modelo de optimización de la red neuronal multicapa.

En esta **Práctica 2**, no implementaremos dicho modelo de optimización, sino que usaremos la librería de *Keras* de *Tensorflow* para optimizar una red neuronal multicapa mediante el modelo secuencial de capas densas.

Resuelve los dos problemas teóricos y responde las preguntas de la práctica. En un documento **PDF** con una portada que contenga la identidad del *Instituto Politécnico Nacional*, el *Centro de Investigación en Computación* y el *Departamento de diplomados y extensión profesional*, con tu nombre completo, correo, así como lugar y fecha, documenta los resultados de la práctica y envíalos por correo a **badillosalas@outlook.com** con el título **Diplomado PyCD 2026 - Práctica 2**. No es necesario poner cuerpo en el correo o adjuntar más archivos, solo el documento PDF es suficiente. El documento PDF se debe llamar *pycd26-SIGLAS.pdf* con las **SIGLAS** formadas por tu nombre y apellidos.

1. Problema 1 - Parámetros de entrenamiento

Una red neuronal multicapa define matrices de pesos en cada capa y por cada neurona, así si tenemos una red neuronal de dos capas ocultas, donde la primera capa tiene 3 neuronas y la segunda 2 neuronas, y una capa de salida de 1 neurona tendríamos la arquitectura $3 \times 2 \times 1$, si la entrada $x^{(i)}$ es un vector de entrada con 10 características, entonces el cálculo del total de parámetros quedaría como:

1. **Capa oculta 1** - $(10 + 1) \cdot 3$ considerando 10 entradas más el bias
2. **Capa oculta 2** - $(3 + 1) \cdot 2$ considerando 3 entradas (salidas de la primera capa) más el bias
3. **Capa de salida** - $(2 + 1) \cdot 1$ considerando 2 entradas (salidas de la segunda capa) más el bias
4. **Total de parámetros** - $33 + 8 + 3 = 44$

Entonces necesitaríamos un total de 44 β para entrenar una red neuronal multicapa de 10 características y 2 capas ocultas de 3×2 neuronas y una capa de salida de 1 neurona.

Completa la siguiente tabla para calcular el total de parámetros de aprendizaje en diferentes arquitecturas:

Entradas	Capas ocultas	Salidas	Total de Parámetros
10	3×2	1	44
8	3×2	1	-
10	3×3	1	-
8	3×3	1	-
10	$5 \times 4 \times 2$	1	-
8	$5 \times 4 \times 2$	1	-
30	$128 \times 64 \times 32$	1	-
30	$128 \times 64 \times 32$	10	-
784	32×32	10	-

1.1. Preguntas de análisis del Problema 1

Responde las siguientes preguntas:

1. ¿Qué representa cada parámetro de entrenamiento?
2. ¿Entre más capas habrá un mejor entrenamiento? ¿Por qué?
3. ¿Si hay pocos datos es mejor más capas o menos capas?
4. ¿Cuál es la mejor arquitectura para 784 características de entrada?

2. Problema 2 - Transformación de características

En el siguiente problema se definen cuatro características relacionadas a casas vendidas en Ames, Iowa, Estados Unidos. Tres de las características son categóricas y una es numérica, la primera característica C_1 representa el tipo de material principal en el revestimiento del exterior de la casa, la segunda característica C_2 representa el tipo de calidad de la cocina y la tercera característica C_3 representa el tipo de zona en la que se ubica la casa, además una cuarta característica C_4 numérica indica el año de construcción de la casa.

Primero introduce una nueva característica $C_5 = 2026 - C_4$ que representará los años de antigüedad y trabajaremos sobre esta característica numérica en lugar de C_4 que es menos informativa.

El objetivo de este problema es transformar las variables categóricas mediante diferentes técnicas de transformación para formar las características numéricas a partir de las características categóricas:

1. C_1 - Expande en *dummies* para cada una de las categorías:

- **HdBoard** - Tablero de fibra dura (*Hardboard*)
- **VinylSd** - Revestimiento de vinilo
- **MetalSd** - Revestimiento metálico
- **Stucco** - Estuco
- **Wd Sdng** - Revestimiento de madera
- **WdShng** - Tejas de madera
- **Plywood** - Madera contrachapada
- **BrkFace** - Fachada de ladrillo
- **AsbShng** - Tejas de asbesto
- **CemntBd** - Tablero de cemento

Y excluye la clase base (de mayor proporción)

2. C_2 - Pondera naturalmente cada una de las categorías:

- **Gd** - Buena (*Good*)
- **TA** - Típica o promedio (*Typical/Average*)
- **Ex** - Excelente (*Excellent*)
- **Fa** - Regular (*Fair*)

3. C_3 - Pondera por la proporción de cada una de las categorías:

- **RL** - Residencial de baja densidad (*Residential Low Density*)

- **FV** - Residencial de villas (*Floating Village*)
 - **RM** - Residencial de densidad media (*Residential Medium Density*)
 - **RH** - Residencial de alta densidad (*Residential High Density*)
4. C_3 - Transforma la zona por el promedio del año de construcción
 5. C_3 - Transforma la zona por la mediana del año de construcción
 6. C_3 - Transforma la zona por la antigüedad promedio
 7. C_3 - Transforma la zona por la desviación estándar de la antigüedad
 8. C_3 - Transforma la zona por la mediana de la antigüedad

2.1. Preguntas de análisis del Problema 2

Responde las siguientes preguntas:

1. ¿Cuál es la clase base para el revestimiento exterior?
2. ¿Cuántas características se extendieron de C_1 en la codificación *One-Hot*?
3. ¿Cuántas veces aumenta la proporción entre las casas en zonas residenciales bajas contra las de alta densidad?
4. ¿Cuál es el año promedio de construcción para las casas residenciales de baja densidad y cuál el de alta densidad?
5. ¿Cuál es la mediana del año de construcción para las casas residenciales de baja densidad y cuál el de alta densidad?
6. ¿Cuál es la antigüedad promedio de construcción para las casas residenciales de baja densidad y cuál el de alta densidad?
7. ¿Cuál es la desviación estándar de la antigüedad de construcción para las casas residenciales de baja densidad y cuál el de alta densidad?
8. ¿Cuál es la mediana de la antigüedad de construcción para las casas residenciales de baja densidad y cuál el de alta densidad?
9. Construye una nueva características numérica que estandarice la característica de antigüedad promedio C_5 con:

$$\hat{C}_5^{(i)} = \frac{C_5^{(i)} - \overline{C_5}}{\sigma_{C_5}}$$

10. De las características numéricas construidas, ¿Cuáles usarías como características predictivas si la respuesta fuera el precio de la casa? ¿Por qué y qué tan linealmente independientes serían?

Exterior1st	KitchenQual	MSZoning	YearBuilt
HdBoard	TA	RL	1971
VinylSd	Gd	RL	1995
MetalSd	Gd	FV	1999
VinylSd	TA	RL	1955
VinylSd	Gd	RL	2001
Stucco	TA	RL	1920
Wd Sdng	Gd	RL	1988
HdBoard	TA	RL	1977
MetalSd	TA	RM	1925
HdBoard	TA	RL	1961
Wd Sdng	TA	RL	1919
VinylSd	TA	RL	1986
VinylSd	Gd	RL	2007
MetalSd	Fa	RL	1941
WdShing	TA	RL	1945
MetalSd	TA	RL	1976
VinylSd	Ex	RL	2007
MetalSd	Gd	RM	1940
VinylSd	TA	RL	1970
Plywood	Gd	RL	1976
VinylSd	TA	RL	1983
MetalSd	TA	RL	1958
VinylSd	TA	RL	1950
BrkFace	TA	RL	1959
Stucco	Gd	RL	1918
HdBoard	TA	RL	1976
Plywood	Gd	RL	1993
Plywood	TA	RL	1959
MetalSd	TA	RL	1962
HdBoard	Gd	RL	1992
VinylSd	Gd	RM	2003
Plywood	TA	RL	1980
Wd Sdng	TA	RM	1920
VinylSd	TA	RH	1965
HdBoard	TA	RL	1978
MetalSd	TA	RM	1920
VinylSd	Gd	RM	2004
HdBoard	TA	RL	1967
VinylSd	Gd	RM	2004
HdBoard	TA	RL	1957
Wd Sdng	Gd	RL	1985
HdBoard	TA	RL	1963
HdBoard	TA	RM	1972
AsbShng	Fa	RM	1936
CemntBd	TA	RM	1971
Stucco	TA	RL	1925
MetalSd	TA	RL	1950
VinylSd	Ex	RL	2006
HdBoard	TA	RL	1966
HdBoard	Gd	RL	1973
Plywood	Gd	RL	1978
VinylSd	Gd	RL	2003
HdBoard	TA	RL	1983
VinylSd	Gd	FV	2009
CemntBd	TA	RM	1973
CemntBd	Ex	RL	2009
Wd Sdng	TA	RL	1941
MetalSd	Gd	FV	2004
CemntBd	Gd	FV	2006
CemntBd	Gd	RL	2001

Tabla 1: Muestra de 60 casas en venta de Ames, Iowa, Estados Unidos.

3. Preguntas de análisis de la práctica

Sobre el código de la práctica, responde las siguientes preguntas de análisis realizado sobre el conjunto de datos del *Titanic*:

1. ¿Cómo interpretas la clase asociada al boleto de los pasajeros? ¿Crees que influye en la supervivencia?
2. De los pasajeros con boleto de de tercera clase, ¿Cuál es la probabilidad de sobrevivir y cuál de no hacerlo?
3. ¿Cómo interpretas el mapa de calor de la supervivencia por clase del boleto? ¿Crees que tiene un comportamiento lineal que los divida?
4. ¿Cómo se comportan las densidades de las tarifas de los que no sobreviven y los que si lo hacen? ¿Qué diferencia hay en las densidades cuando se aplica el logaritmo corregido más uno?
5. Explica cada una de las características predictivas que se construyeron para predecir la supervivencia
6. ¿Crees que exista colinealidad entre las características predictivas construidas o son linealmente independientes? ¿Cómo podrías justificarlo?
7. ¿Qué exactitud de predicción logra el perceptrón con función de activación *sigmoid*?
8. ¿Qué exactitud de predicción logra la red neuronal con una capa oculta de 16 neuronas tipo *ReLU* y con una salida con función de activación *sigmoid*?
9. ¿Qué exactitud de predicción logra la red neuronal con tres capas ocultas de 16, 8 y 4 neuronas tipo *ReLU* y con una salida con función de activación *sigmoid*?
10. ¿Crees que una red neuronal con más capas ocultas mejorará la predicción?
11. ¿Qué falta en el análisis para validar que no haya sobreajuste en el aprendizaje?

4. Método de evaluación

Cada pregunta respondida correctamente tendrá valdrá 1 punto, y cada respuesta aproximada solo medio punto. Hay 30 puntos totales en esta práctica. No hay fecha de entrega programada, tienen el resto del módulo para resolver la práctica, serán 3 prácticas totales y dos de ellas deberán aprobarlas con una calificación mayor a 6/10.

Mucho éxito en su práctica :D