




muestras (datos)

↳ observación (registro)



Conjunto de Datos
(espacio de características)

	C1	C2	...	Cd
1	Sedán	Hombre		No
2	Camioneta	Mujer		Ligera
...				
n	Hatchback	Hombre		Fuerte

- Categóricas → Numérico

- Numéricas $\in \mathbb{R}$

$C_j \in \{A, B, C\}$

¿Cómo representar una característica categórica en numérica?

Expansión del espacio

$C_j^{(A)} \rightarrow 0/1$


$C_j^{(B)} \rightarrow 0/1$ linealmente dependientes

$C_j^{(C)} \rightarrow 0/1$

	C_j	$C_j^{(A)}$	$C_j^{(B)}$	$C_j^{(C)}$
1.	A	1	0	0
2.	A	1	0	0
3.	B	0	1	0
4.	A	1	0	0
5.	C	0	0	1
6.	B	0	1	0
7.	A	1	0	0
8.	B	0	1	0
9.	A	1	0	0
10.	C	0	0	1

Problema de colinealidad

Sobreinformación



$$ax_1 + bx_2 + cx_3 = d$$

$$x_1 = -\frac{b}{a}x_2 - \frac{c}{a}x_3 + \frac{d}{a}$$

$$x_1 = \lambda_1 x_2 + \lambda_2 x_3 + d$$

$$y = X\beta + \beta_0$$

$$y = X\beta$$

$$\beta = X^{-1}y$$

!! X^{-1} no existe


Nota:

Transformación directa

A - 0
B - 1
C - 2

Ejemplo 2 - Escalaridad

C_1	C_2
A Ninguno	+5,000
B Primaria	+7,000
C Secundaria	+10,000
D Preparatoria	+12,000
E Universidad	+18,000
F Posgrado	+23,000



A - 0
B - 1
C - 2
D - 3
E - 4
F - 5

↑ artificial / hipótesis / expertise
↑ lógica / Factor / índice

i. Secundaria | \$16,000

↳ 1.4 | \$16,000

Categoría Base (A)

$C_j^{(A)} = 50\%$

$C_j^{(B)} = 30\%$

$C_j^{(C)} = 20\%$

$C_j^{(B)}, C_j^{(C)}$

1, 0

0, 1

0, 0 → $C_j^{(A)}$

1, 1

Espacio Características

Espacio numérico

X
 $x_1, x_2, \dots, x_k$
 y
 $y_1, y_2, \dots$

Números
 $\downarrow$
 -30, ..., 30
 II
 I escalares
 (normalizar)
 características

X - Predictivas

Características

y - Respuestas

cerrada (espacio acotado)
 $y \in \{0, 1\}$
 $y \in [0, 1], [-1, 1]$

abierta (espacio no acotado / semiacotado)
 $y \in (-100, 100)$
 $y \in (-\infty, \infty)$

prior

posterior

$y \in [a, b]$

$$y' = \frac{y-a}{b-a} \in [0, 1]$$

logístico

Clasificación






Regresión



Conjunto de datos $\rightarrow$ Histórico de observaciones

A	B
identificar	alcanzar
$\downarrow$	$\downarrow$
Evento	Costo



Información no estándar
 (escala / dispersión)

Información estándar
 (escala / dispersión)

Standard Scaler

Receso

9:00 -

9:10 pm


Espacio lineal

	x_i	y_i
1.	20	\$2,500
2.	30	\$2,800
3.	25	\$2,500
4.	40	\$4,500
5.	60	\$5,600

x_i - Horas de trabajo

y_i - Salario


5-observaciones (nube de datos)



$$y = \varphi(x, \beta)$$


Modelo paramétrico (de pesos β)

$\beta^{(0)}$
 $\beta^{(1)}$



Función generalizada

$$y = \varphi(x, \beta)$$



$$\nabla E = \frac{\partial \varphi}{\partial \beta}$$

$$e = y - y_p$$

$$(+0.4k, -0.4k, -0.2k, +1.4k, +2.0k)$$

MSE

$$0.16 + 0.16 + 0.04 + 1.96 + 4$$

$$SE = 6.32$$

$$MSE = SE / 5 = 1.264$$

$$RMSE = \sqrt{MSE} = 1.1242$$

$$\begin{aligned} & \$3,624 \\ & \$2,500 \\ & \$1,375 \end{aligned}$$

Espacio lineal (2)

$$y = \varphi(x, \beta)$$

$$\begin{aligned} y^{(1)} &= \varphi(x^{(1)}, \beta) \\ y^{(2)} &= \varphi(x^{(2)}, \beta) \\ &\vdots \\ y^{(n)} &= \varphi(x^{(n)}, \beta) \end{aligned}$$


$$\underbrace{y}_{\text{constante}} = \varphi\left(\underbrace{x}_{\text{variable}}, \underbrace{\beta}_{\text{constante}}\right)$$

X	y
20	\$2,500
30	\$2,800
25	\$2,500
40	\$4,800
60	\$5,600

Modelo lineal generalizado

$$y = mx + b$$

recta
con pendiente m
e intercepción b




$$y = mx + b$$


$\downarrow \quad \downarrow$
 $\beta_1 \quad \beta_0$

$$y = \beta_0 + \beta_1 x$$

$$\beta = (\beta_0, \beta_1)$$



$$\varphi(x, \beta) = \bar{x} \cdot \beta$$



$$y = \varphi(x, \beta)$$

$$y = \underbrace{(1, x)}_{\text{vec. de diseño}} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}$$

β_0
 β_1
pesos

$$y = \bar{x} \cdot \beta^{(0)} \quad \beta^*$$